文本分类

教师：邱锡鹏 微博：@邱锡鹏

1 文本分类任务简介

在有监督学习中,需要提供一组有类别标记的样本用来学习模型以及检验模型的好 坏。这组样本集合就称为数据集。数据集用 X 表示,$X = (x^1, y^1), \cdots, (x^N, y^N)$,N 为 样本个数。$y^i$ 为样本实例 x^i 的类别标记。在自然语言处理中,数据集也经常称为语料库。

其中x^i的为一组文本，y^i可以是一组标签如词性，也可以是一个标签如文本的类别

$$\begin{aligned} x^i &= (w_1 \ldots w_t \ldots w_T) \\ y^i &= (p_1 \ldots p_t \ldots p_T) \end{aligned}$$

使用机器学习方法 - 即找到这样一个映射f， 使得$x^i - > y^i$

2 向量化

在机器学习算法中,样本实例一般是以连续变量或离散变量的形式存在的(也称为 特征),而在自然语言处理中一般都是文字形式。因此,在进行学习模型之前,需要进行 特征提取,将样本的原始表示转换为特征向量。

在机器学习中,为了更好地表示样本的属性,一般将样本表示成代数形式,称为样 本的特征,我们用$\phi(x)$。样本特征可以是一维或多维向量,$\phi(x) \in R_m, m$是向量维数。

$$\phi(x) = \begin{pmatrix} \phi_1(x) \\ \phi_2(x) \\ . \\ . \\ \phi_m(x) \end{pmatrix}$$

自然语言处理中,数据都是以字符形式存在的。样本的原始表示一般是字符串序 列。为了便于使用机器学习方法,首先要把样本表示为向量形式。下面我们介绍几种常 用的特征表示方法。自然语言处理的,在构造了样本和样本集合之后,为了和后面的机 器学习算法相结合,我们将样本x 转变成向量φ(x)。在将字符表示转换成向量表示的过 程中需要很多中间步骤,我们把这些中间步骤都成为数据处理,并且尽可能的模块化。

2.1 词袋模型

一种简单的方法是简单假设文本(如一个句子或一个文档)是由字、词组成的无序 多重集合,不考虑语法甚至词序。这就是在自然语言处理和信息检索中常用的词袋模型，词袋模型可以看成一种以词为基本单位的向量空间模型(Vector Space Model, VSM)。具体可见本课程chap3的slide

2.2 N 元特征

词袋模型在需要深层分析的场合就会显得太过简化了。例如在语义分析里,“你打了 我”和 “我打了你”,意思是相反的,但用词袋模型表示后,这两句话是向量表示的等价 的,这显然是不合理的。

N 元特征(N-gram 特征),顾名思义,就是由 N 个字或词组成的字符串,单元可以 是字或词。这里N是大于等于1的任意整数。如果N 为2,就叫做二元特征,如果N为 3,就叫做三元特征以此类推。

N 元特征可以看出是对词袋模型的一种改进方法。与 N 元特征相关的概念是 N 元语法模型。以中文句子“机器学习算法”为例,以字为基本单位的二元特征集合为:{机器,器 学,学习,习算,算法}。集合中每一项都是由二个相邻的字组成的的子串,长度为 2。这 些子串可以是有意义的词(例如:“学习”、“算法”),也可以是无任何意义的字符串(例 如:“器学”,“习算”)。但是这些无意义的子串也有可能在分类中起到很关键的作用。一 个长度为L的句子,可以提取出L − 1个二元特征。

有了 N 元特征集合,就可以利用词袋模型将文本表示为向量形式。随着 N 的增加, 可以抽取的特征就会越多,特征空间也会呈指数增加。这些高阶的特征出现的频率也会相对较低,对分类不但没有太多帮助,还会直接影响着后续处理的效率与复杂度。因此在一般的文本分类任务中,N 取 3 就足够了,并且同时也使用一元和二元特征,防止出现过拟合。

3 文本分类

经过特征抽取后,一个样本可以表示为 k 维特征空间中的一个点。为了对这个特征 空间中的点进行区分,就需要寻找一些超平面来将这个特征空间分为一些互不重叠的子 区域,使得不同类别的点分布在不同的子区域中,这些超平面就成为判别界面。

为了定义这些用来进行空间分割的超平面,就需要引入判别函数的概念。假设变量 z ∈ Rm为特征空间中的点,这个超平面由所有满足函数f(z) = 0的点组成。这里的f(z) 就称为判别函数。

有了判别函数,分类就变得很简单,就是看一个样本在特征空间中位于哪个区域, 从而确定这个样本的类别。 判别函数的形式多种多样,在自然语言处理中,最为常用的判别函数为线性函数。

3.1 二分类问题

$$\hat{y} = sign((f(z))) = sign(\theta^T z + \theta_0)$$

sign为符号函数，取判别函数f(z)的正负号，为方便，简写判别函数为

$$f(z)=\theta^T z + \theta_0 = \sum_{i=1}^{k} \theta_i z_i + \theta_0 = \sum_{i=0}^{k} = \hat{\theta}^T \hat{z}$$

其中$z_0 = 1$,$\hat{\theta}, \hat{z}$分别称为增广权重向量和增光特征向量。

$$\hat{z} = \begin{pmatrix} 1 \\ z_1 \\ . \\ . \\ z_k \end{pmatrix} = \begin{pmatrix} 1 \\ \\ z \\ \\ \end{pmatrix}$$

$$\hat{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \\ . \\ . \\ \theta_k \end{pmatrix} = \begin{pmatrix} \theta_0 \\ \\ \theta \\ \\ \end{pmatrix}$$

后面的分类器描述中,我们都采用简化的表示方法,并直接用 θ, z 来表示增广权重向量和增广特征向量

3.2 多分类问题

对于 C 类分类问题,需要定义 C 个判别函数。但是这种表示一般适用于类别 y 为离散变量的情况。在自然语言处理的很 多学习任务,类别 y 可以是更复杂的结构,比如多标签、层次化以及结构化等形式。为了更好的描述这些情况，可采用如下形式：

$$\hat{y} = \underset{y}{argmax}\, f(\phi(x,y),\theta) \qquad \text{式}3.2$$

这里$\phi(x,y)$是包含了样本x和类别y混合信息的特征向量，$\theta=[\theta_1;\theta_2\ldots;\theta_C]$

例子：

$$\phi_1(x,y)=\begin{cases}1 & \text{if x contains 'stock' and y is 'eco'}\\ 0 & \text{otherwise}\end{cases}$$

$$\phi_2(x,y)=\begin{cases}1 & \text{if x contains 'stock' and y is 'sport'}\\ 0 & \text{otherwise}\end{cases}.$$

其中$x=w_1\ldots w_{|V|}$ ，是个字典大小的向量。

总之：

$$\phi(x,y)=\begin{pmatrix}\phi_1(x,y)\\ \phi_2(x,y)\\ .\\ .\\ \phi_{|V|*k}(x,y)\end{pmatrix}=\phi(x)\otimes\phi(y)$$

其中：

$$\phi_k(x)=\begin{cases}1 & \text{if x contains c}_k\\ 0 & \text{otherwise}\end{cases}$$

c_k是词典中第k个词。

$$\phi_m(y)=\begin{cases}1 & \text{if y is label}_m\\ 0 & \text{otherwise}\end{cases}$$

$label_m$表示第m个标签。

再论式3.2：

$\phi(x,y)$ 为特征表示，$f(\phi,\theta)$为模型，一般在文本分类中为线性模型（由于我们可以构建足够复杂的特征表示，在高维空间中总是线性可分的），argmax 为解码过程，即寻求y解的过程，对于分类问题，看得分取高分即可。机器学习要学的参数是θ。

4 词性标注

y的输出值可能不仅仅是分类值，可能也是一个序列值，如词性标注问题 - 输入一个序列，输出也是一个序列：

X：(S) I give you a book (E)

y:　　　P　V　　P　D　N

其中P为代词，V为动词，D为冠词，N为名词，(S)为开始符，(E)为结束符

1. 初级处理方法：

如(I, P),(give, V),(you,P),(a,D),(book,N) 构建一个多分类器

2. 进阶处理方法：

由于一个词的词性与其上下文相关，可以构建大小为n**窗口**，如n为1

可以增加以下:

((S) I give, N), (give you a, P)...

通过构建一个特征更多的多分类器。

但是仍然存在一个问题：相近词的词性约束缺失。

3. CRF(条件随机场):

$$\phi(x,y)=\sum_{i=1}^{L}\theta_i^T\phi(\vec{x},y_i)+\sum_{i=2}^{L}\theta_i^T\phi^*(\vec{x},y_{i-1},y_i)$$

L为序列化输出y的长度。

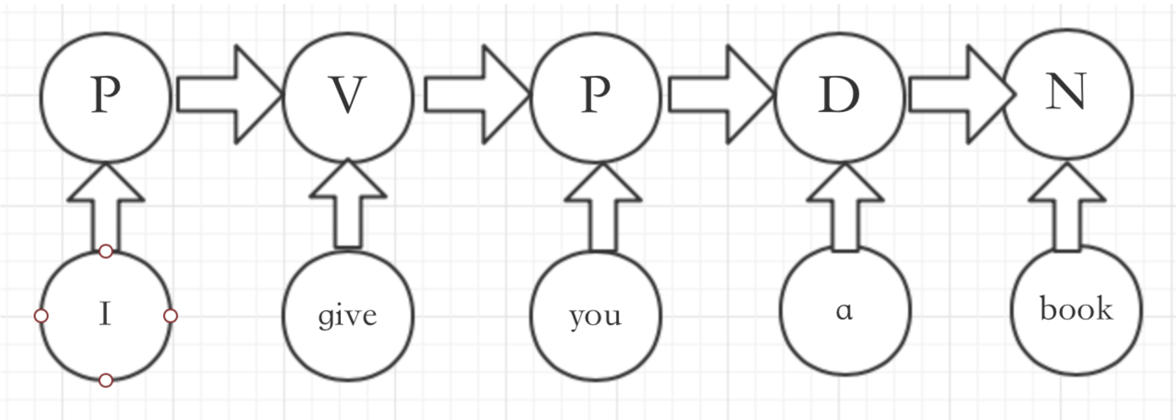

其中$\phi(\vec{x},y)$中特征抽取方式如下 - 假定窗口为1:

$$\phi_1(x,y_i)=\begin{cases}1 & if\ x_{i+1}\ =\ 'a'\ and\ x_{i-1}\ =\ 'give'\ and\ y_i=P\\ 0 & \text{otherwise}\end{cases}$$

其中$\phi^*(\vec{x},y_{i-1},y_i)$特征抽取方式如下:

$$\phi^*(x,y_{i-1},y_i)\approx\phi^*(y_{i-1},y_i)=\begin{cases}1 & if\ y_{i-1}\ =\ V\ and\ y_i=P\\ 0 & \text{otherwise}\end{cases}$$

5 感知器训练

5.1训练算法

输入:训练集: $(x_i,y_i),i=1,\cdots,N$,最大迭代次数:T 输出: θ_k

$\theta_0=0;$
$k=1;$
$for\ t=1\cdots T\ do$

$shuffle$

$for\ i=1\cdots N\ do$

选取一个样本 (xi , yi);

预测类别 $\hat{y}_t$;

$if\ \hat{y}_t=y_t\ then$

$\theta_k = \theta_{k-1} + (\varphi(x_t, y_t) - \varphi(x_t, \hat{y}_t));$

$k = k + 1;$

end

end

end

$return\ \theta_T;$

算法要点：

1. 单个样本进行学习
2. 被动学习，只有预测值和实际值不同时才更新
3. 每次一轮迭代前进行shuffle
4. early-stop避免过拟合，将集合分成训练集，开发集和测试集。

5.2 感知器收敛性

5.2.1 定义

多类线性可分：对于训练集$D = (x_i, y_i)_{i=1}^n$,如果存在一个正的常数$\gamma(\gamma > 0)$和权重向量θ^*,并且$\|\theta^*\| = 1$,对所有i都满足 $\langle\theta^*, \varphi(x_i, y_i)\rangle - \langle\theta^*, \varphi(x_i, y)\rangle > \gamma, y \neq y_i (\varphi(x_i, y_i) \in R^m$ 为样本x_i的增广特征向量),那么训练集D 是线性可分的。

5.2.2 定理

对于任何线性可分的训练集$D = (x_i, y_i)_{i=1}^n$,假设 R 是所有样本中错误类别和真实类别在特征空间 φ(x, y) 最远的距离。

$R = max_i\, max_{z \neq y_i} \| \varphi(x_i, y_i) - \varphi(x_i, z)\|$

那么在5.1感知器学习算法中,总共的预测错误次数$K < \frac{R^2}{\gamma^2}$